

Ejemplos

Temas Selectos II

Dr. Rubén Blancas Rivera

Departamento de Actuaría, Física y Matemáticas
Universidad de las Américas Puebla

Primavera 2026



1 Procesos de Decisión de Markov con Dos Estados

2 Inventarios de un producto

MDP con dos estados

- Consideramos un MDP estacionario con dos estados: $S = \{s_1, s_2\}$.
- En cada **época de decisión** el sistema está en un estado y se elige una acción disponible.
- La acción produce:
 - ▶ una **recompensa inmediata** (o costo),
 - ▶ y una **transición probabilística** al siguiente estado.
- La representación permite que la recompensa dependa del **estado actual** y, si se desea, también del **siguiente estado**.

Componentes del MDP (notación formal)

Épocas de decisión

$$T = \{1, 2, \dots, N\}, \quad N \leq \infty.$$

Estados

$$S = \{s_1, s_2\}.$$

Acciones admisibles

$$A(s_1) = \{a_{1,1}, a_{1,2}\}, \quad A(s_2) = \{a_{2,1}\}.$$

Recompensa inmediata estacionaria $r_t(s, a)$:

$$r_t(s_1, a_{1,1}) = 5, \quad r_t(s_1, a_{1,2}) = 10, \quad r_t(s_2, a_{2,1}) = -1.$$

Si el horizonte es finito ($N < \infty$), recompensa terminal:

$$r_N(s_1) = 0, \quad r_N(s_2) = 0.$$

- $r_t > 0$ es recompensa; $r_t < 0$ puede interpretarse como costo.

Probabilidades de transición

Probabilidades estacionarias $p_t(s' \mid s, a)$:

$$p_t(s_1 \mid s_1, a_{1,1}) = 0.5,$$

$$p_t(s_2 \mid s_1, a_{1,1}) = 0.5,$$

$$p_t(s_1 \mid s_1, a_{1,2}) = 0,$$

$$p_t(s_2 \mid s_1, a_{1,2}) = 1,$$

$$p_t(s_1 \mid s_2, a_{2,1}) = 0,$$

$$p_t(s_2 \mid s_2, a_{2,1}) = 1.$$

- Desde s_2 se permanece en s_2 con probabilidad 1.
- La acción $a_{1,2}$ en s_1 lleva a s_2 con certeza.

Resumen en tabla

Estado s	Acción a	Recompensa $r(s, a)$	Transición $p(\cdot \mid s, a)$
s_1	$a_{1,1}$	5	$p(s_1) = 0.5, p(s_2) = 0.5$
s_1	$a_{1,2}$	10	$p(s_1) = 0, p(s_2) = 1$
s_2	$a_{2,1}$	-1	$p(s_1) = 0, p(s_2) = 1$

Variante: recompensa dependiente del siguiente estado

A veces se modela la recompensa como $r_t(s, a, s')$ (depende del estado siguiente).

Ejemplo: para la acción $a_{1,1}$ en s_1 :

$$r_t(s_1, a_{1,1}, s_1) = 3, \quad r_t(s_1, a_{1,1}, s_2) = 7,$$

y las probabilidades permanecen

$$p_t(s_1 \mid s_1, a_{1,1}) = 0.5, \quad p_t(s_2 \mid s_1, a_{1,1}) = 0.5.$$

- Si el siguiente estado es s_1 , se gana 3; si es s_2 , se gana 7.
- Esto captura recompensas “ligadas” al resultado de la transición.

Políticas Markovianas (Horizonte $N = 3$)

Supongamos $N = 3$. Las decisiones se toman en épocas $t = 1, 2$.

Una política se representa como:

$$\pi = (d_1, d_2).$$

Época 1:

$$d_1^{MD}(s_1) = a_{1,1}, \quad d_1^{MD}(s_2) = a_{2,1}.$$

Época 2:

$$d_2^{MD}(s_1) = a_{1,2}, \quad d_2^{MD}(s_2) = a_{2,1}.$$

- La acción está completamente determinada por el estado.
- No hay aleatorización.

Época 1:

$$q_1^{MR}(s_1, a_{1,1}) = 0.7, \quad q_1^{MR}(s_1, a_{1,2}) = 0.3,$$

$$q_1^{MR}(s_2, a_{2,1}) = 1.$$

Época 2:

$$q_2^{MR}(s_1, a_{1,1}) = 0.4, \quad q_2^{MR}(s_1, a_{1,2}) = 0.6,$$

$$q_2^{MR}(s_2, a_{2,1}) = 1.$$

- La acción se selecciona aleatoriamente.
- Depende únicamente del estado actual (propiedad Markov).

Recompensa Total (Horizonte Finito)

Para una trayectoria (X_1, X_2, X_3) :

$$J^\pi(s) = \mathbb{E}_s^\pi [r_1(X_1, A_1) + r_2(X_2, A_2)].$$

- No hay recompensa terminal en $t = 3$.
- El objetivo es maximizar $\mathbb{E}[\text{recompensa total}]$.

1 Procesos de Decisión de Markov con Dos Estados

2 Inventarios de un producto

- Un productor decide *cuánto producir* para satisfacer demanda aleatoria.
- Hay inventario, costos de producción/ajuste y penalizaciones por faltantes o exceso.
- Se busca una política óptima para minimizar costo de largo plazo (o maximizar ganancia).
- Esto se modela naturalmente como un **MDP**: decisiones secuenciales + incertidumbre.

Componentes del MDP

Un MDP se especifica por:

$$(X, A, Q, \mathbf{c})$$

- $\mathbf{X}$: espacio de estados.
- $\mathbf{A}$: acciones disponibles (dependen del estado).
- $\mathbf{Q}(\cdot \mid x, a)$: kernel de transición.
- $\mathbf{c}(x, a)$: costo inmediato.

Usaremos un estado compuesto:

$$x = (y, n) \in \mathbf{X},$$

donde

- $y \in [0, M]$: nivel de inventario (capacidad M).
- $n \in \{0, 1\}$: modo de máquina (por ejemplo, 0 = apagada, 1 = encendida).

Interpretación: en cada época t observamos (y_t, n_t) y decidimos una acción $a_t \in A(y_t, n_t)$.

Acciones (decisión de producción)

En cada estado (y, n) se elige una acción a (cantidad a producir/ordenar):

$$a \in A(y, n) \subseteq [0, \bar{a}],$$

con restricciones típicas:

- Capacidad: $0 \leq a \leq \bar{a}$.
- Capacidad de inventario: $y + a \leq M$ (si aplica).
- Acciones pueden depender de n (p. ej. si $n = 0$ no se produce).

Demanda aleatoria y dinámica del inventario

Sea Z_t la demanda en la época t (i.i.d.):

$$Z_t \sim g(\cdot) \quad \text{en } [\varepsilon, M],$$

$$y_{t+1} = (y_t + a_t n_t - Z_t)^+, \quad (\cdot)^+ = \max\{0, \cdot\}.$$

Idea:

- Se produce a_t si la máquina está encendida ($n_t = 1$).
- Se satisface demanda Z_t y se actualiza inventario.

Kernel de transición $\mathbf{Q}$ (forma típica)

Para $x = (y, n)$ y acción $a \in A(y, n)$, el siguiente estado $x' = (y', n')$ es aleatorio.

Una forma común (mezcla con “reset”):

$$\mathbf{Q}(\cdot \mid x, a) = (1 - \alpha) \mu(\cdot) + \alpha P(\cdot \mid x, a), \quad \alpha \in (0, 1).$$

- μ : medida “base” (reinicio/exógeno).
- $P(\cdot \mid x, a)$: dinámica inducida por la demanda (y reglas de n).

Costo inmediato $\mathbf{c}(x, a)$

Un costo típico en inventarios:

$$\mathbf{c}((y, n), a) = c_{\text{prod}}(a, n) + c_{\text{hold}}(y) + c_{\text{pen}}(\text{faltante}),$$

por ejemplo:

- Producción: $c_{\text{prod}}(a, n) = K \mathbf{1}_{\{a > 0\}} + p a n$.
- Mantenimiento/inventario: $h y$.
- Penalización por faltante (vía $y_{t+1} = (\cdot)^+$ o variable adicional).

Objetivo de optimización

Ejemplos de criterios:

(i) Costo total finito (horizonte N):

$$\mathbb{E} \left[\sum_{t=0}^{N-1} \mathbf{c}(X_t, A_t) \right].$$

(ii) Costo promedio (largo plazo):

$$\limsup_{N \rightarrow \infty} \frac{1}{N} \mathbb{E} \left[\sum_{t=0}^{N-1} \mathbf{c}(X_t, A_t) \right].$$

Inventario clásico en 3 periodos: idea

- Consideramos $N = 3$ periodos.
- En cada periodo t observamos el inventario disponible X_t .
- Elegimos cuánto ordenar/producir $a_t \geq 0$ (decisiones en $t = 1, 2$).
- La demanda D_t es aleatoria y ocurre dentro del periodo.
- El inventario evoluciona según “inventario menos demanda”.

Estado, acción y dinámica (sin DP)

Estado (inicio del periodo): $X_t \geq 0$.

Acción: ordenar $a_t \geq 0$.

Inventario después de ordenar:

$$Y_t = X_t + a_t.$$

Demanda aleatoria: D_t .

Inventario para el siguiente periodo:

$$X_{t+1} = (Y_t - D_t)^+ = \max\{0, Y_t - D_t\}.$$

- Interpretación: si la demanda excede el inventario, se vende todo y queda 0.
- (Modelo de *lost sales*.)

Costos típicos (inventario clásico)

Costos usuales en el periodo t :

- **Costo fijo de ordenar:** $K \mathbf{1}_{\{a_t > 0\}}$.
- **Costo unitario:** $c a_t$.
- **Costo de mantener inventario:** $h X_{t+1}$.
- **Penalización por faltantes (opcional):** $p (D_t - Y_t)^+$.

Costo total en 3 periodos (sin DP):

$$\sum_{t=1}^2 \left(K \mathbf{1}_{\{a_t > 0\}} + c a_t + h X_{t+1} + p (D_t - Y_t)^+ \right) + (\text{costo terminal en } t = 3).$$

Estrategia umbral tipo (s, S)

Una política umbral clásica usa dos niveles $s < S$.

Regla de decisión:

$$a_t(X_t) = \begin{cases} S_t - X_t, & \text{si } X_t \leq s_t, \\ 0, & \text{si } X_t > s_t, \end{cases} \quad t = 1, 2.$$

- Si el inventario es **bajo** (por debajo de s_t), reabastecemos hasta S_t .
- Si el inventario es **suficiente**, no ordenamos.
- En horizonte finito, los umbrales pueden cambiar por periodo:
 (s_1, S_1) y (s_2, S_2) .

Ejemplo numérico (3 periodos)

Supongamos que usamos:

$$(s_1, S_1) = (1, 3), \quad (s_2, S_2) = (0, 2).$$

Entonces:

- **Periodo 1:** si $X_1 \leq 1$, ordenar $a_1 = 3 - X_1$; si $X_1 > 1$, ordenar $a_1 = 0$.
- **Periodo 2:** si $X_2 \leq 0$, ordenar $a_2 = 2 - X_2$; si $X_2 > 0$, ordenar $a_2 = 0$.
- **Periodo 3:** no se ordena (cierre/solo se incurre en costo terminal si se incluye).

Interpretación: en los primeros periodos se “corrige” inventario bajo; al acercarse el final, los niveles objetivo suelen ser menores.