

Problemas a Horizonte Infinito

Temas Selectos II

Dr. Rubén Blancas Rivera

Departamento de Actuaría, Física y Matemáticas
Universidad de las Américas Puebla

Primavera 2026



1 El valor de una política

2 Ejemplo 1

3 Ejemplo 2

Proceso inducido por una política

En un MDP estacionario de horizonte infinito, una política

$$\pi = (d_1, d_2, \dots)$$

induce el proceso estocástico:

$$\{(X_t, r(X_t, A_t)); t = 1, 2, \dots\}$$

donde:

- X_t = estado en el tiempo t
- A_t = acción elegida en t
- $r(X_t, A_t)$ = recompensa inmediata

El proceso es bivariado en tiempo discreto.

Reglas de decisión deterministas

La regla de decisión d_t determina la acción A_t .

Caso Markoviano determinista (D^{MD}):

$$A_t = d_t(X_t)$$

Caso dependiente de la historia (D^{HD}):

$$A_t = d_t(Z_t)$$

donde Z_t representa la historia del proceso hasta el tiempo t .

Reglas de decisión aleatorizadas

Si d_t es aleatorizada:

Markoviana aleatorizada (D^{MR}):

$$P\{A_t = a\} = q_{d_t, X_t}(a)$$

Dependiente de la historia aleatorizada (D^{HR}):

$$P\{A_t = a\} = q_{d_t, Z_t}(a)$$

Si π es Markoviana, entonces

$$\{(X_t, r(X_t, A_t))\}$$

es un proceso de recompensa de Markov.

Valor de una política: recompensa total esperada

Para una política π , el valor en el estado inicial s se define como:

$$v^\pi(s) = \lim_{N \rightarrow \infty} \mathbb{E}_s^\pi \left[\sum_{t=1}^N r(X_t, A_t) \right]$$

También puede escribirse como:

$$v^\pi(s) = \lim_{N \rightarrow \infty} v_{N+1}^\pi(s)$$

Observaciones importantes

- El límite puede ser $+\infty$ o $-\infty$.
- En algunos modelos el límite puede no existir.
- Es necesario estudiar condiciones de convergencia.
- Las políticas estacionarias $d^\infty = (d, d, \dots)$ juegan un papel central.

Interpretación

El valor $v^\pi(s)$ representa:

La recompensa total esperada al iniciar en s
y seguir la política π durante un horizonte infinito.

Problema central del MDP:

$$v^*(s) = \sup_{\pi} v^\pi(s)$$

$$\pi^* = \arg \max_{\pi} v^\pi(s)$$

Cuando el límite existe y se puede intercambiar límite y esperanza:

$$v^\pi(s) = \mathbb{E}_s^\pi \left[\sum_{t=1}^{\infty} r(X_t, A_t) \right]$$

Observación:

- El valor puede ser $+\infty$ o $-\infty$.
- En algunos modelos el límite no existe.
- No siempre es un criterio apropiado.

Recompensa total descontada

Para $0 \leq \lambda < 1$:

$$v_{\lambda}^{\pi}(s) = \lim_{N \rightarrow \infty} \mathbb{E}_s^{\pi} \left[\sum_{t=1}^N \lambda^{t-1} r(X_t, A_t) \right]$$

Si

$$\sup_{s \in S} \sup_{a \in A_s} |r(s, a)| = M < \infty$$

entonces el límite existe y

$$|v_{\lambda}^{\pi}(s)| \leq \frac{M}{1 - \lambda}$$

Cuando el límite existe:

$$v_{\lambda}^{\pi}(s) = \mathbb{E}_s^{\pi} \left[\sum_{t=1}^{\infty} \lambda^{t-1} r(X_t, A_t) \right]$$

Interpretación:

- λ es el factor de descuento.
- Recompensas futuras valen menos.
- Garantiza convergencia bajo recompensas acotadas.

Recompensa promedio (criterio de ganancia)

La recompensa promedio de la política π es:

$$g^\pi(s) = \lim_{N \rightarrow \infty} \frac{1}{N} \mathbb{E}_s^\pi \left[\sum_{t=1}^N r(X_t, A_t) \right]$$

También:

$$g^\pi(s) = \lim_{N \rightarrow \infty} \frac{1}{N} v_{N+1}^\pi(s)$$

Cuando el límite no existe

Definimos:

$$g_-^\pi(s) = \liminf_{N \rightarrow \infty} \frac{1}{N} v_{N+1}^\pi(s)$$

$$g_+^\pi(s) = \limsup_{N \rightarrow \infty} \frac{1}{N} v_{N+1}^\pi(s)$$

El promedio existe si:

$$g_-^\pi(s) = g_+^\pi(s)$$

Comparación de criterios

Criterio	Convergencia	Uso típico	Estabilidad
Total	No siempre	Teórico	Baja
Descontado	Sí ($\lambda < 1$)	RL / Control	Alta
Promedio	Bajo condiciones	Sistemas estables	Media

1 El valor de una política

2 Ejemplo 1

3 Ejemplo 2

Ejemplo

Estados:

$$S = \{s_1, s_2\}$$

Acciones:

$$A_{s_1} = \{a_{1,1}, a_{1,2}\}, \quad A_{s_2} = \{a_{2,1}\}$$

Recompensas:

$$r(s_1, a_{1,1}) = 5, \quad r(s_1, a_{1,2}) = 10,$$

$$r(s_2, a_{2,1}) = -1$$

Transiciones:

$$p(s_1|s_1, a_{1,1}) = 0.5, \quad p(s_2|s_1, a_{1,1}) = 0.5$$

$$p(s_2|s_1, a_{1,2}) = 1$$

$$p(s_2|s_2, a_{2,1}) = 1$$

Solo existen dos políticas Markovianas:

$$d(s_1) = a_{1,1}, \quad d(s_2) = a_{2,1}$$

$$e(s_1) = a_{1,2}, \quad e(s_2) = a_{2,1}$$

Ambas eventualmente llevan al estado absorbente s_2 .

Recompensa Total Esperada

Para $N \geq 1$:

$$v_{N+1}^d(s_1) = 10 - (N - 1)$$

$$v_{N+1}^d(s_2) = -N$$

Por lo tanto:

$$\lim_{N \rightarrow \infty} v_N^d(s) = \lim_{N \rightarrow \infty} v_N^e(s) = -\infty$$

Conclusión: El criterio total diverge.

Recompensa Descontada

Para $0 \leq \lambda < 1$:

$$v_{\lambda}^e(s_1) = \frac{10 - 11\lambda}{1 - \lambda}$$

$$v_{\lambda}^e(s_2) = -\frac{1}{1 - \lambda}$$

$$v_{\lambda}^d(s_1) = \frac{10 - 11\lambda}{(2 - \lambda)(1 - \lambda)}$$

$$v_{\lambda}^d(s_2) = -\frac{1}{1 - \lambda}$$

Comportamiento cuando $\lambda \rightarrow 1$

$$v_{\lambda}^d(s) \rightarrow \infty, \quad v_{\lambda}^e(s) \rightarrow \infty$$

El descuento controla la divergencia, pero al quitar el descuento el valor explota.

Como el proceso es absorbido en s_2 :

$$r(s_2, a_{2,1}) = -1$$

Entonces:

$$g^d(s) = g^e(s) = -1$$

para $s = s_1, s_2$.

Comparación de Criterios

Criterio	¿Existe?	Valor	Comentario
Total	No	$-\infty$	Diverge
Descontado	Sí	Depende de λ	Controlado
Promedio	Sí	-1	Estable

Este ejemplo muestra que:

- El criterio total puede no ser adecuado.
- El descuento garantiza convergencia.
- El promedio captura el comportamiento asintótico.
- El límite cuando $\lambda \rightarrow 1$ no siempre coincide con el promedio.

1 El valor de una política

2 Ejemplo 1

3 Ejemplo 2

Estados:

$$S = \{1, 2, 3, \dots\}$$

Acción única:

$$A_s = \{a_s\}$$

Transiciones:

$$p(s+1 \mid s, a_s) = 1$$

Recompensa:

$$r(s, a_s) = (-1)^{s+1} s$$

Solo existe una política π .

Trayectoria del sistema

Desde cualquier estado inicial:

$$1 \rightarrow 2 \rightarrow 3 \rightarrow 4 \rightarrow \dots$$

Recompensas:

$$1, -2, 3, -4, 5, -6, \dots$$

Serie alternante creciente.

Recompensa Total Esperada

Para $N > 1$:

$$v_N^\pi(1) = \begin{cases} k & N = 2k \\ -k & N = 2k + 1 \end{cases}$$

$$k = 1, 2, \dots$$

Entonces:

$$\limsup_{N \rightarrow \infty} v_N^\pi(1) = +\infty$$

$$\liminf_{N \rightarrow \infty} v_N^\pi(1) = -\infty$$

El valor total no existe.

$$g_+^\pi(1) = \frac{1}{2}$$

$$g_-^\pi(1) = -\frac{1}{2}$$

Como:

$$g_+^\pi(1) \neq g_-^\pi(1)$$

La recompensa promedio no existe.

A pesar de que la recompensa es no acotada:

$$v_{\lambda}^{\pi}(1) = \frac{1}{(1 + \lambda)^2}$$

Es finita para todo $0 \leq \lambda < 1$.

Comparación con Ejemplo 1

Ejemplo	Total	Promedio	Descontado
1	Diverge	Existe	Existe
2	No existe	No existe	Existe

Conclusión:

- El criterio descontado es el más robusto.
- No requiere convergencia del total.
- Puede funcionar incluso con recompensas no acotadas.