

Actividad 1

Temas Selectos II (Aprendizaje por Refuerzo)

Prof. Rubén Blancas Rivera

August 22, 2025

Indicaciones Generales

Trabajo en equipo (máximo 2 personas).

Entrega:

1. Un `Jupyter Notebook` que incluya:
 - Desarrollo matemático detallado.
 - Explicación paso a paso del algoritmo.
 - Código comentado.
 - Resultados numéricos e interpretación.
2. Un video (máximo 10 minutos) donde el equipo:
 - Explique el modelo.
 - Justifique la política evaluada.
 - Interprete los resultados obtenidos.

No se aceptarán entregas sin explicación matemática detallada. No se evaluará únicamente el código.

Ejercicio 1

Considere un MDP estacionario con espacio de estados:

$$X = \{s_1, s_2, s_3\}.$$

Interpretación:

- s_1 : sistema en estado favorable,
- s_2 : sistema en estado intermedio,
- s_3 : sistema en estado crítico.

En cada estado se pueden tomar las siguientes acciones:

$$A(s_1) = \{a_1, a_2\}, \quad A(s_2) = \{a_1, a_2\}, \quad A(s_3) = \{a_2\}.$$

Las recompensas inmediatas están dadas por:

$$\begin{aligned} r(s_1, a_1) &= 6, & r(s_1, a_2) &= 4, \\ r(s_2, a_1) &= 3, & r(s_2, a_2) &= 5, \\ r(s_3, a_2) &= -2. \end{aligned}$$

Las probabilidades de transición están dadas por:

$$\begin{aligned} P(\cdot | s_1, a_1) &= (0, 7, 0, 3, 0), \\ P(\cdot | s_1, a_2) &= (0, 4, 0, 6, 0), \\ P(\cdot | s_2, a_1) &= (0, 2, 0, 5, 0, 3), \\ P(\cdot | s_2, a_2) &= (0, 1, 0, 6, 0, 3), \\ P(\cdot | s_3, a_2) &= (0, 0, 4, 0, 6). \end{aligned}$$

Se considera un horizonte finito $N = 4$.

Actividades

1. Especifique formalmente el MDP como (X, A, Q, r) .
2. Escriba la ecuación de Bellman para horizonte finito.
3. Evalúe una política Markoviana determinista propuesta por el equipo.
4. Evalúe una política Markoviana aleatorizada propuesta por el equipo.
5. Compare ambas políticas en términos de recompensa total esperada.
6. Verifique los resultados mediante simulación Monte Carlo (al menos 5000 trayectorias).
7. Interprete económicamente los resultados.

Ejercicio 2

Considere un sistema de inventario con horizonte $N = 3$.

Estado al inicio del periodo:

$$X_t \in \{0, 1, 2, 3, 4\}.$$

Acción:

$$a_t \in \{0, 1, 2\},$$

sujeta a $X_t + a_t \leq 4$.

Demanda aleatoria:

$$D_t \in \{0, 1, 2\},$$

con

$$P(D_t = 0) = 0,2, \quad P(D_t = 1) = 0,5, \quad P(D_t = 2) = 0,3.$$

Dinámica (modelo con ventas perdidas):

$$X_{t+1} = \max\{0, X_t + a_t - D_t\}.$$

Costos:

- Costo fijo de ordenar: $K = 2$ si $a_t > 0$.

- Costo unitario: $c = 1$.
- Costo de mantener inventario: $h = 1$ por unidad.
- Penalización por faltante: $p = 4$ por unidad no satisfecha.

Actividades

1. Especifique formalmente el MDP (X, A, Q, c) .
2. Derive explícitamente la ley de transición.
3. Evalúe una política determinista tipo umbral propuesta por el equipo.
4. Evalúe una política Markoviana aleatorizada.
5. Compare el costo total esperado de ambas políticas.
6. Realice simulación Monte Carlo para validar resultados.

Ejercicio 3

Considere un MDP con espacio de estados:

$$X = \{0, 1, 2\}.$$

En cada periodo se elige una acción:

$$A(x) = \{0, 1\},$$

donde la acción $a = 1$ representa “intervenir” y $a = 0$ “no intervenir”.

Recompensa inmediata:

$$r(x, 0) = x, \quad r(x, 1) = x - 2.$$

Probabilidades de transición:

$$P(\cdot|x, 0) = \begin{cases} (0, 6, 0, 4, 0), & x = 0, \\ (0, 0, 7, 0, 3), & x = 1, \\ (0, 0, 1), & x = 2, \end{cases}$$

$$P(\cdot|x, 1) = \begin{cases} (1, 0, 0), & x = 0, \\ (0, 8, 0, 2, 0), & x = 1, \\ (0, 5, 0, 5, 0), & x = 2. \end{cases}$$

Considere horizonte finito $N = 5$.

Actividades

1. Especifique formalmente el MDP (X, A, Q, r) .
2. Escriba la ecuación de Bellman para horizonte finito:

$$V_t(x) = \max_{a \in A(x)} \left\{ r(x, a) + \sum_{y \in X} P(y|x, a) V_{t+1}(y) \right\}.$$

3. Resuelva explícitamente la etapa final $t = N - 1$.
4. Describa el algoritmo de **Backward Induction**.
5. Implemente el algoritmo en Python.
6. Reporte:
 - Funciones de valor $V_t(x)$.
 - Política óptima por periodo.
7. Interprete la estructura de la política óptima.

Ejercicio 4

Considere un sistema de inventario con horizonte $N = 4$.

Estado:

$$X_t \in \{0, 1, 2, 3\}.$$

Acciones:

$$a_t \in \{0, 1, 2\}, \quad X_t + a_t \leq 3.$$

Demanda aleatoria:

$$P(D_t = 0) = 0,3, \quad P(D_t = 1) = 0,4, \quad P(D_t = 2) = 0,3.$$

Dinámica:

$$X_{t+1} = \max\{0, X_t + a_t - D_t\}.$$

Costos por periodo:

- Costo fijo de ordenar: $K = 2$ si $a_t > 0$.
- Costo unitario: $c = 1$.
- Costo de mantenimiento: $h = 1$ por unidad de inventario final.
- Penalización por faltante: $p = 5$ por unidad insatisfecha.

El costo total esperado es:

$$\mathbb{E} \left[\sum_{t=0}^{N-1} c(X_t, a_t) \right].$$

Actividades

1. Especifique formalmente el MDP (X, A, Q, c) .
2. Derive explícitamente el kernel de transición.
3. Escriba la ecuación de Bellman para minimizar costo:

$$V_t(x) = \min_{a \in A(x)} \left\{ \mathbb{E}[c(x, a)] + \sum_{y \in X} P(y|x, a) V_{t+1}(y) \right\}.$$

4. Resuelva explícitamente la última etapa.
5. Implemente Backward Induction.
6. Reporte:

- Función de valor por periodo.

- Política óptima por periodo.
7. Analice si emerge una estructura tipo política umbral.
 8. Compare la política del periodo inicial con la del periodo final.

Criterios de Evaluación

- Modelación formal correcta: 20 %.
- Desarrollo matemático detallado: 20 %.
- Implementación computacional correcta: 20 %.
- Comparación y simulación: 20 %.
- Interpretación y claridad en el video: 20 %.

Nota: El énfasis de la está en la explicación rigurosa del procedimiento seguido. El código sin justificación matemática no será considerado suficiente.